

The 20 Newsgroups

Progetto di Text Mining and Search
di Beatrice Fumagalli e Matteo Porcino

Dataset 20—newsgroups

1997 documenti suddivisi in 20 newsgroups:

- alt.atheism
- comp.graphics
- comp.os.ms-windows.misc
- comp.sys.ibm.pc.hardware
- comp.sys.mac.hardware
- comp.windows.x
- misc.forsale
- rec.autos
- rec.motorcycles
- rec.sport.baseball
- rec.sport.hockey
- sci.crypt
- sci.electronics
- sci.med
- sci.space
- soc.religion.christian
- talk.politics.guns
- talk.politics.mideast
- talk.politics.misc
- talk.religion.misc

Text pre-processing

Dataset suddiviso in *Training set* (70%, 13997 articoli) e *Test set* (30%, 6000 articoli)

- Eliminazione dei metadata
- Eliminazione delle contrazioni
- Rimozione di URLs e indirizzi e-mail
- Tokenization
- Rimozione di righe vuote e tabs
- Rimozione della punteggiatura ed eventuali ulteriori spazi vuoti
- Eliminazione delle stringhe numeriche
- Normalizzazione dei caratteri in minuscolo
- Rimozione delle stop-words
- Eliminazione dei caratteri non unicode
- Eliminazione della punteggiatura
- Stemming e Lemmatization
- Eliminazione dei tokens di lunghezza inferiore a 2

Utilizzo della libreria NLTK

Text Representation

- **Term Frequencies (TF):** la Term Frequency $tf_{t,d}$ del termine t nel documento d è definito come il numero di volte che t si verifica in d .
- **Term Frequency times Inverse Document Frequency (TF-IDF):** il peso $tf-idf$ di un termine è il prodotto del suo peso tf e del suo peso idf .

Utilizzo della libreria scikit-learn

Ciascuna rappresentazione fornisce una matrice Document-Term di dimensioni 13997x119613

Text Classification

Multinomial Naive Bayes

- TF: accuracy = 0.812
- TF-IDF: accuracy = 0.848

Logistic Regression

- TF: accuracy = 0.809
- TF-IDF: accuracy = 0.823

Random Forest

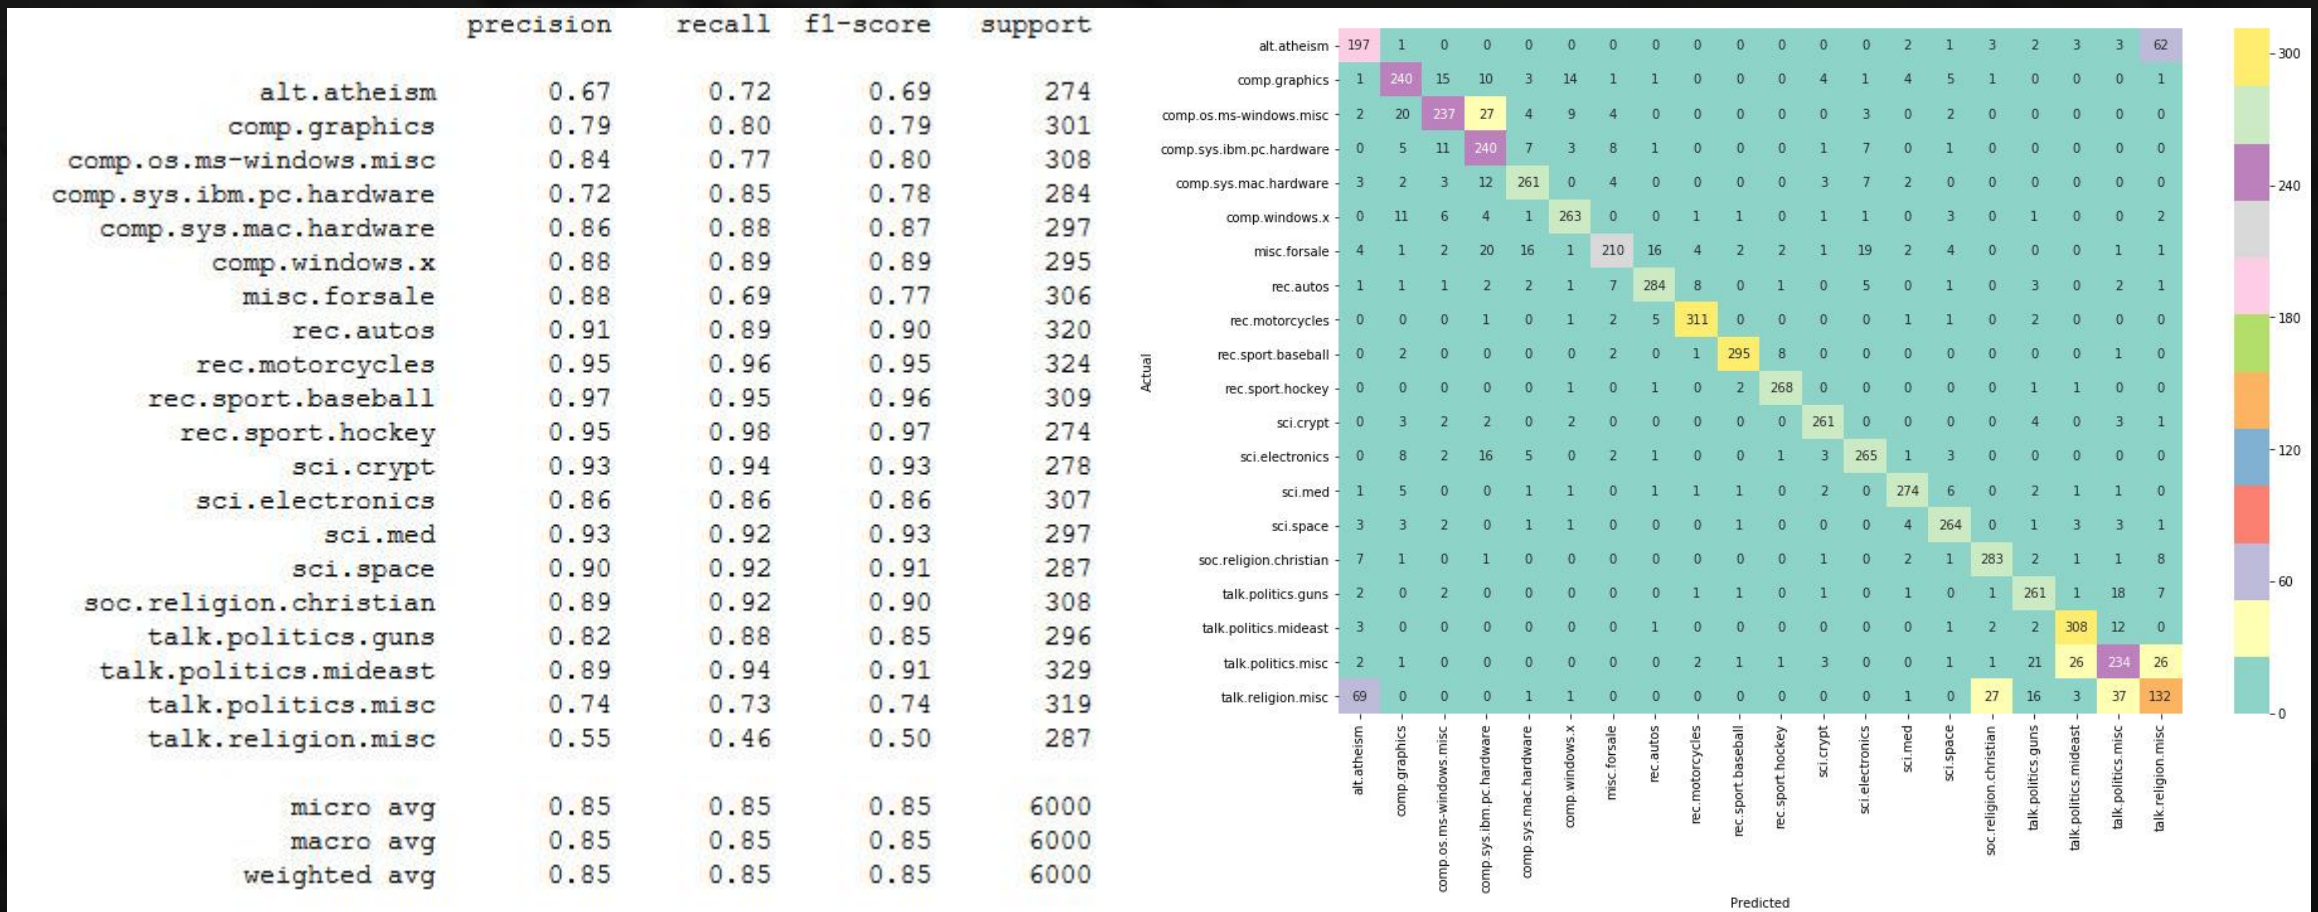
- TF: accuracy = 0.619
- TF-IDF: accuracy = 0.626

Support Vector Machine

- TF: accuracy = 0.754
- TF-IDF: accuracy = 0.840

Risultati

Naive Bayes, TF-IDF:



Risultati

Support Vector Machine, TF-IDF:

[illegible]